

Erkennung und Auslesen von Nummernschildern aus Bilddateien mithilfe von Deep Learning und Optical Character Recognition

Christian Peters

3. März 2021

Veranstaltung: Fallstudien II
Dozent: Prof. Dr. Markus Pauly
Gruppe: Anne-Sophie Bollmann, Susanne Klöcker,
Pia von Kolken, Christian Peters

Inhaltsverzeichnis

1	Einleitung	1
2	Datenbeschreibung	1
3	Grundlagen	2
3.1	Neuronale Netze	2
3.2	OpenCV	3
3.3	Tesseract	3
4	Pipeline	3
5	Ergebnisse	3
6	Zusammenfassung	3
	Literatur	4

1 Einleitung

Die automatisierte Erkennung von Nummernschildern aus Bilddateien ist ein wichtiger Bestandteil vieler moderner Verkehrssysteme und kommt beispielsweise in Parkhäusern, Mautstellen oder bei der Identifikation gestohlener Fahrzeuge zum Einsatz [7].

Das Ziel dieses Projektes ist es, einen Prototypen für ein solches Erkennungssystem zu entwickeln, welcher in der Lage sein soll, erfolgreich Nummernschilder aus Bilddateien erkennen und auszulesen zu können.

Zu diesem Zweck kommen bei der Entwicklung des Prototypen Methodiken aus dem Bereich des Deep Learning, sowie der Optical Character Recognition zum Einsatz, die in Abschnitt 3 näher beschrieben werden. Ein Überblick über das vorliegende Datenmaterial, welches zum Training dieser Algorithmen verwendet wurde, wird in Abschnitt 2 gegeben. Abschließend werden die erzielten Ergebnisse in Abschnitt 5 beschrieben und die Stärken sowie die Schwächen des Prototypen diskutiert.

Der gesamte Quellcode dieses Projekts ist Open Source und kann unter https://github.com/cxan96/license_plate_detection abgerufen werden.

2 Datenbeschreibung

Der vorliegende Datensatz besteht aus insgesamt 949 Bildern von Autos mit Nummernschildern.¹ Die Bilder wurden in den Regionen Brasilien, Europa, Rumänien und USA aufgenommen.

Zu jedem Bild liegen außerdem Informationen zur Position des Nummernschildes innerhalb des Bildes anhand von Pixel Koordinaten vor. Die Position des Nummernschildes ist dabei durch die Koordinaten x_{\min} , x_{\max} , y_{\min} , y_{\max} relativ zur linken oberen Ecke des Bildes eindeutig spezifiziert.

In Abbildung 1 sind drei Beispielbilder aus dem Datensatz dargestellt. Die Koordinaten der Nummernschilder sind anhand der roten Rechtecke eingezeichnet.




Abbildung 1: Drei Beispiele aus dem vorliegenden Datensatz. Die Nummernschilder sind anhand ihrer Koordinaten rot umrandet.

¹Die Originaldaten sind unter https://github.com/phibuc/Lab_FS_Data, sowie unter <https://github.com/RobertLucian/license-plate-dataset> einsehbar.

3 Grundlagen

3.1 Neuronale Netze

Neuronale Netze sind eine Modellklasse, welche zur Lösung des bereits ausführlich in [5] beschriebenen Problems des statistischen Lernens eingesetzt werden können. In dieser Problemsituation wird angenommen, dass sich der Zusammenhang zwischen beobachtbaren Prädiktorvariablen X_1, \dots, X_p , welche sich durch einen Vektor $X = (X_1, \dots, X_p)$ zusammenfassen lassen, und einer Zielvariable Y durch eine Funktion f^* mit $Y = f^*(X) + \epsilon$ modellieren lässt. Hierbei kann ϵ als eine zufällige Störgröße angesehen werden, die hier im weiteren Verlauf aber keine wichtige Rolle spielt. Das Ziel von Neuronalen Netzen ist es, die unbekannte Funktion f^* zu approximieren.

Die folgenden Erklärungen zum Aufbau und zum Training neuronaler Netze stützen sich wesentlich auf [4] und sind hier auf das grundlegendste reduziert.

3.1.1 Aufbau

Wie in 3.1 angedeutet, definiert ein neuronales Netz also eine Abbildung f , welche den Zusammenhang zwischen einer Eingabe X und einer Ausgabe Y approximieren soll. Eine Hauptcharakteristik von neuronalen Netzen ist es, dass die Funktion f durch die Verkettung weiterer Funktionen gebildet wird. Ist ein neuronales Netz beispielsweise durch $f(x) = f^{(3)}(f^{(2)}(f^{(1)}(x)))$ gegeben, so setzt es sich aus der Verkettung der einzelnen Funktionen $f^{(1)}$, $f^{(2)}$ und $f^{(3)}$ zusammen. Wie genau diese Funktionen aussehen können, soll an dieser Stelle bewusst erst einmal offen bleiben.

Solche Ketten von Funktionen können gut durch azyklische Graphen beschrieben werden. Hierbei wird jedes Zwischenergebnis durch einen Knoten repräsentiert, jede Kante zwischen zwei Knoten beschreibt die Operation, die vom einen Ergebnis zum nächsten geführt hat. Der Beispielgraph zu $f(x) = f^{(3)}(f^{(2)}(f^{(1)}(x)))$ ist in Abbildung 2 zu sehen.




Abbildung 2: Verkettung dreier Funktionen dargestellt als azyklischer Graph.

Im Kontext von neuronalen Netzen wird jede der Funktionen $f^{(1)}$, $f^{(2)}$ und $f^{(3)}$ auch als eine **Schicht** im neuronalen Netz bezeichnet. Da $f^{(1)}$ und $f^{(2)}$ im Inneren des Netzwerks

liegen, bezeichnet man diese Schichten auch als **versteckte Schichten**.

3.1.2 Training

3.1.3 Convolutional Neural Networks

3.2 OpenCV

3.3 Tesseract

4 Pipeline

5 Ergebnisse

6 Zusammenfassung

Literatur

- [1] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. Software available from <http://www.tensorflow.org>.
- [2] G. Bradski. The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 2000.
- [3] F. Chollet. *Deep Learning with Python*. Manning Publications Co., 2017.
- [4] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [5] G. James, D. Witten, T. Hastie, and R. Tibshirani. *An Introduction to Statistical Learning*. Springer-Verlag New York, 2013.
- [6] M. A. Nielsen. *Neural Networks and Deep Learning*. Determination Press, 2015. <http://neuralnetworksanddeeplearning.com/>.
- [7] S. M. Silva and C. R. Jung. License plate detection and recognition in unconstrained scenarios. In *2018 European Conference on Computer Vision (ECCV)*, pages 580–596, Sep 2018.
- [8] R. Smith. An overview of the tesseract ocr engine. *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)*, 2:629–633, 2007.